

CHULETA DE SUSTENTACION

Mini-JARVIS · Elena · Britany Macias

Rosa = lo que haces con las manos. Negro = lo que dices.

ANTES DE ENTRAR

App abierta y probada. El laboratorio ya cargado: la primera vez tarda.

Internet funcionando. Saldo en Together AI comprobado.

Volumen del portatil arriba. Microfono cerca.

ARRANQUE · los primeros 30 segundos

Mini-JARVIS es un asistente de voz en espanol. Se llama Elena.

Hace tres cosas: oye, piensa y habla. Y trae un laboratorio que abre el Transformer por dentro.

No entrene ningun modelo: uso modelos preentrenados, que es lo que pedia el enunciado.

Lo que si hice fue abrir uno para poder explicar que le pasa a una frase.

LAS CINCO PIEZAS · que es cada una

Los nombres solos no se pueden defender. Esto es lo que ES cada uno.

Whisper large-v3 · EL OIDO

Que es: un modelo que convierte audio en texto. Le das sonido, devuelve lo dicho por escrito.

Quien lo hizo: OpenAI. Es abierto y gratuito.

Por que ese: esta entrenado en muchos idiomas a la vez, y por eso el espanol le sale bien. Otros estan pensados para el ingles y con el espanol fallan mas.

No piensa. Solo transcribe. Si dices una tonteria, la transcribe tal cual.

Qwen3.8-2.4T-A95B · EL CEREBRO

Que es: un modelo de lenguaje grande. Lee texto y escribe la respuesta. Es el que conversa.

Quien lo hizo: Alibaba.

Por que ese: es un modelo de razonamiento: antes de contestar trabaja el problema por dentro. Va mejor con preguntas que hay que pensar, no solo recordar.

Es el que decide cuando usar una herramienta. Si le preguntas la hora no se la inventa: pide que se ejecute la herramienta hora.

Llama-3.3-70B-Instruct · EL CEREBRO DE REPUESTO

Que es: otro modelo de lenguaje, del mismo tipo.

Quien lo hizo: Meta, los de Facebook.

Por que esta: por si el principal cae. El 70B son setenta mil millones de parametros, que son los numeros que aprendio al entrenarse.

De otra empresa a proposito: si los dos fueran de Alibaba, un problema del proveedor te deja sin ninguno.

edge-tts · LA BOCA

Que es: aqui hay un matiz. NO es un modelo, es una libreria: un programa pequeno que habla con el servicio de voz de Microsoft, el mismo que usa el navegador Edge para leer paginas en voz alta.

Que hace: le das texto y devuelve audio con una voz que suena natural.

Por que ese: es gratis, no necesita clave, y tiene buenas voces en espanol. De ahi sale Elena, que es una voz argentina.

BETO · EL MICROSCOPIO

Que es: un modelo de lenguaje pequeño, 110 millones de parámetros, entrenado SOLO en español.

Quien lo hizo: la Universidad de Chile.

Por que esta: BETO NO conversa. No habla con nadie. Esta solo para el laboratorio.

Por que hace falta: los otros corren en servidores ajenos y solo devuelven texto. BETO se descarga a mi laptop, se abre por dentro, y de ahí salen los tokens y el mapa de atención.

Resumen de una línea

Whisper oye · Qwen piensa · Llama piensa si el otro cae · edge-tts habla

BETO no hace nada de eso: se deja mirar por dentro.

LAS SEIS PREGUNTAS DEL ENUNCIADO

1. Que es un token? Muestralo.

HACER: Laboratorio -> Ver los tokens.

Token = el pedazo más chico que el modelo entiende.

Puede ser palabra entera, trozo de palabra o un signo.

El modelo no ve letras. Ve números, uno por token.

Mini-JARVIS se parte en 4 pedazos porque no existe en el vocabulario del modelo.

Y batería y portátil se parten en 3 cada una, porque llevan tilde.

CUIDADO: dos botones, dos tokenizadores distintos

«ver los tokens» usa el de Qwen. «mapa de atención» usa el de BETO.

La palabra Wikipedia son 2 pedazos en Qwen y 6 en BETO. Si dices «seis» mientras enseñas la tabla de tokens, la pantalla te contradice: ahí salen dos. Los seis solo se ven en las etiquetas del mapa de atención.

Y si te preguntan por que salen números distintos, esa es una buena respuesta: cada modelo tiene su propio vocabulario, así que el número de tokens no es una propiedad del texto, depende del modelo que lo lea.

Si ves símbolos raros como 'ÁÑa' donde decía 'ia', NO es un error. El tokenizador de Qwen trabaja sobre los bytes del texto, y una letra acentuada ocupa dos bytes. Por eso las palabras con tilde se parten en más pedazos.

2. Que es self-attention y por que es clave?

HACER: Laboratorio -> Mapa de atención. (Aquí SI, Wikipedia son 6 pedazos.)

Cada fila es una palabra preguntando a quien mirar. Lo brillante es a quien mira.

Es clave porque una palabra cambia de significado según su contexto.

Banco de río no es banco de calle. Lo decide a quien atiende.

Cada fila suma uno. Reparte el cien por cien de su atención.

Suma UNO, no cien. Es una distribución de probabilidad, no un porcentaje. Ese detalle impresiona si lo dices bien.

3. Y si la conversación pasa la ventana de contexto?

HACER: Señala el contador de memoria, debajo de los deslizadores.

El modelo no recuerda nada entre llamadas.

La ilusión se logra reenviando la conversación entera cada vez.

Pero eso no crece infinito: hay límite y se paga por token.

Guardo diez turnos. Tiro el más viejo, nunca el más nuevo.

Corto por turnos y no por tokens porque es predecible y se demuestra en pantalla.

El error más común es decir que el modelo recuerda. No recuerda: se le reenvía todo cada turno.

4. Como defines la personalidad? Muestra el system prompt.

HACER: Boton system prompt.

Esto recibe el modelo antes de cada frase mia.

Es lo unico que define quien es Elena.

Le digo como se llama, que es una IA y que puede equivocarse.

Y que escriba frases cortas sin listas: se leen en voz alta. Una vineta no se pronuncia.

Cuidado con decir que la entrenaste. No entrenaste nada, y el enunciado decia que no hacia falta.

5. Diferencia con un modelo base sin fine-tuning?

Un modelo base solo continua texto.

Le dices hola quien eres y te inventa la conversacion en vez de contestar.

El mio paso por instruction-tuning: le enseñaron que una pregunta se responde.

Por eso el nombre lleva la palabra Instruct.

Sin esa etapa el system prompt no serviria: un base no obedece, continua.

Las tres etapas, en orden: preentrenamiento (aprende a continuar texto), fine-tuning (se especializa en un tema), instruction-tuning (aprende a obedecer).

6. Que pasa si cambias temperatura o top_p? Demuéstralo.

HACER: Temperatura casi a cero, pregunta algo. Subela, pregunta lo mismo.

Temperatura = cuanto riesgo corre al elegir la palabra siguiente.

Cerca de cero: elige la mas probable. Predecible, de manual.

Alta: se permite opciones raras. Mas creativo y mas errores.

Top_p es otro camino: se queda con las mas probables hasta ese porcentaje.

No confundas la temperatura con la longitud: eso lo controla el maximo de tokens, que es otro parametro. Y si preguntan por que el slider llega a 1.4 y no a 2: lo medi. Desde 1.5 el modelo se atascaba cien segundos en dos de cada tres intentos.

PALABRAS QUE TE PUEDEN PEDIR QUE EXPLIQUES

Parametros: los numeros que el modelo aprendio durante su entrenamiento. Mas parametros, normalmente mas capaz. BETO tiene 110 millones; Llama, setenta mil millones.

Embedding: una lista de numeros que representa el significado de un token. En BETO son 768 numeros por token. Palabras con usos parecidos acaban con listas parecidas.

API: una direccion web por la que mi programa habla con el modelo. Mando texto y recibe texto. Nada mas pasa por ahi: por eso no puedo ver los pesos de atencion del modelo de la nube.

Tool calling: el modelo recibe la lista de lo que puede pedir y, cuando hace falta, responde pidiendo una herramienta en vez de texto. El programa la ejecuta y le devuelve el resultado.

Encoder y decoder: el encoder lee la frase entera mirando a los dos lados; sirve para comprender. El decoder escribe palabra por palabra mirando solo hacia atras; sirve para generar. BETO es encoder; el de Elena es decoder.

Softmax: la funcion que convierte una lista de puntajes en probabilidades que suman uno. Es la razon de que cada fila del mapa de atencion suma exactamente uno.

ARQUITECTURA EN UNA LINEA

Micro -> Whisper (texto) -> LLM + memoria + herramientas -> edge-tts -> audio

Todo lo coordina el orquestador. La ventana solo muestra el estado.

La grabacion nunca toca el disco: vive en memoria, se transcribe y se descarta.

MODO SIN INTERNET · esto no lo pedian

Si se cae la red, las tres piezas cambian solas a equivalentes que corren en mi laptop.

faster-whisper para oir. Un Qwen2.5 de 0.5B para pensar. La voz de Windows para hablar.

Responde peor: el local es unas mil veces mas chico. Esta escrito en el informe.

No duplique codigo: envolvi las tres piezas de nube, cada una con su equivalente local. El orquestador ni se entera. Por eso anadirlo no obligo a tocar la logica de la conversacion.

Y el cambio no es ciego: distingue quedarse sin red de tener la clave mal escrita. Si es la clave no cambia, porque eso taparia un error en vez de enseñarlo.

DECISIONES QUE TOME · por si preguntan por que

Dos modelos de familias distintas: a tres dias de la entrega el proveedor retiro el alterno. Probe los 169 del catalogo y solo veinte respondian.

La calculadora no evalua: evaluar ejecutaria cualquier cosa que el modelo escriba. Analizo la expresion y admito solo aritmetica. El modelo propone; decidir que se ejecuta le toca al programa.

Un hilo por turno, no asyncio: la libreria de la ventana no es asincrona y mezclarlas da fallos raros. Un hilo por turno es mas simple y se entiende de un vistazo.

Memoria por turnos, no por tokens: contar tokens exacto necesita el tokenizador del proveedor y depende de la red. Por turnos es predecible y se ensena en pantalla.

LIMITACIONES · dilas tu primero

Puede alucinar: inventa un dato y lo dice con el mismo tono que uno cierto.

Sin internet responde bastante peor.

El modelo principal es cerrado: no veo sus pesos ni con que se entreno, asi que tampoco puedo auditar sus sesgos.

La transcripcion falla con ruido o si hablas lejos del microfono.

Depende de que quede saldo en la API.

Decirlas tu suma. Que te las saquen ellos, resta. Y lo de no poder auditar los sesgos es un nivel mas: reconoces el limite de tu propia revision.

ETICA · los cinco puntos del enunciado

Ninguna clave en el repositorio. Van en .env, que git ignora. Lo comprobe sobre todo el historial, no solo el ultimo commit.

Elena avisa al arrancar que es una IA y que puede equivocarse. Tambien lo lleva en su system prompt, asi que si le preguntan que es, lo responde.

La voz no se guarda en disco. Se transcribe y se descarta.

Limitaciones documentadas en el informe, no escondidas.

Modelos y proveedores citados explicitamente.

SI FALLA ALGO EN VIVO

No te calles. Narra lo que pasa.

Tarda mucho -> "esto es latencia de red, la peticion viaja a un servidor"

No entiende -> repite mas cerca del micro. Es el reconocimiento de voz, no el modelo.

Cae la red -> perfecto, ensena el modo local. Suma en vez de restar.

Error en pantalla -> "esto es el manejo de errores, la app no se cae"

SI NO SABES ALGO

No inventes.

Di: eso no lo medi, lo que si comprobe es esto otro.

Y llevalo a algo que si hiciste.

Reconocer un limite y redirigir a evidencia real demuestra que sabes distinguir lo que verificaste de lo que no. Inventar es lo unico que puede hundirte.