

CHULETA DE SUSTENTACION

Mini-JARVIS · Elena · Brittany Macias

ANTES DE ENTRAR

App abierta y probada.
Internet funcionando. Saldo en Together AI.
Laboratorio ya cargado (tarda la primera vez).
Volumen del portatil arriba.

ARRANQUE (30 segundos)

Mini-JARVIS es un asistente de voz en espanol. Se llama Elena.
Hago tres cosas: oigo, pienso y hablo.
Oigo con Whisper. Pienso con un LLM. Hablo con edge-tts.
Y traigo un laboratorio que abre el Transformer por dentro.

LAS SEIS PREGUNTAS

1. Que es un token? Muestralo.

HACER: Laboratorio -> Ver los tokens.

Token = el pedazo mas chico que el modelo entiende.
Puede ser palabra entera, trozo de palabra o un signo.
El modelo no ve letras. Ve numeros, uno por token.
Wikipedia se parte en seis pedazos porque no esta en su vocabulario.

2. Que es self-attention y por que es clave?

HACER: Laboratorio -> Mapa de atencion.

Cada fila es una palabra preguntando a quien mirar.
Lo brillante es a quien mira.
Es clave porque una palabra cambia de significado segun su contexto.
Banco de rio no es banco de calle. Lo decide a quien atiende.
Cada fila suma uno. Reparte el cien por cien de su atencion.

3. Y si la conversacion pasa la ventana de contexto?

HACER: Senala el contador de memoria.

El modelo no recuerda nada entre llamadas.
La ilusion se logra reenviando la conversacion entera cada vez.
Pero eso no crece infinito: hay limite y se paga por token.
Guardo diez turnos. Tiro el mas viejo, nunca el mas nuevo.
Corto por turnos y no por tokens porque es predecible y se demuestra.

4. Como defines la personalidad? Muestra el system prompt.

HACER: Boton system prompt.

Esto recibe el modelo antes de cada frase mia.
Es lo unico que define quien es Elena.

Le digo como se llama, que es una IA y que puede equivocarse.

Y que escriba frases cortas sin listas: se leen en voz alta.

Una vineta no se pronuncia.

5. Diferencia con un modelo base sin fine-tuning?

Un modelo base solo continua texto.

Le dices hola quien eres y te inventa la conversacion en vez de contestar.

El mio paso por instruction-tuning: le enseñaron que una pregunta se responde.

Por eso el nombre lleva la palabra Instruct.

Sin esa etapa el system prompt no serviría: un base no obedece, continua.

6. Que pasa si cambias temperatura o top_p? Demuéstralo.

HACER: Temperatura casi a cero, pregunta algo. Subela, pregunta lo mismo.

Temperatura = cuanto riesgo corre al elegir la palabra siguiente.

Cerca de cero: elige la mas probable. Predecible, de manual.

Alta: se permite opciones raras. Mas creativo y mas tonterias.

Top_p es otro camino: se queda con las mas probables hasta ese porcentaje.

Si preguntan por que el slider llega a 1.4 y no a 2: lo medi. Desde 1.5 el modelo se atascaba cien segundos en dos de cada tres intentos.

MODELOS: cual y por que

Oír · Whisper large-v3 · entrenado en muchos idiomas, va bien en español

Pensar · Qwen3.8-2.4T-A95B · el principal, razona mejor

Alternar · Llama-3.3-70B-Instruct · por si el principal cae

Hablar · edge-tts, voz es-AR-ElenaNeural

Laboratorio · BETO · solo español, y me deja ver la atención por dentro

Por que dos modelos: uno cayó a tres días de la entrega. Probe los 169 del catalogo y solo 20 respondían. Por eso hay alternar.

Por que BETO y no el de la app: el de la app es de otra empresa y está cerrado. No puedo abrirlo. BETO se descarga y se mira por dentro.

ARQUITECTURA EN UNA LINEA

Micro -> Whisper (texto) -> LLM + memoria + herramientas -> edge-tts -> audio

Todo lo coordina el orquestador. La ventana solo muestra el estado.

MODO SIN INTERNET (esto no lo pedían)

Si se cae la red, cambia solo a modelos que corren en mi laptop.

faster-whisper para oír. Qwen 0.5B para pensar. La voz de Windows para hablar.

Responde peor: el local es mil veces mas chico. Está escrito en el informe.

Distingue sin internet de clave mal puesta. Si es la clave, no cambia: sería tapar un error.

LIMITACIONES (dilas tu primero)

Puede alucinar. Inventar con seguridad.

Sin internet responde bastante peor.

El modelo es de otra empresa: no veo sus pesos ni con que se entreno.

Depende de saldo en la API.

Decirlas tu suma. Que te las saquen ellos, resta.

ETICA

Ninguna clave en el repositorio. Van en .env, ignorado por git.
Elena avisa al arrancar que es una IA y que puede equivocarse.
Tu voz no se guarda en disco. Se transcribe y se descarta.
Limitaciones documentadas en el informe.
Modelos y proveedores citados en el informe.

SI FALLA ALGO EN VIVO

No te calles. Narra lo que pasa.

Tarda mucho -> "esto es latencia de red, la petición viaja a un servidor"
No entiende -> repite mas cerca del micro. Es STT, no el modelo.
Cae la red -> perfecto, ensena el modo local. Suma en vez de restar.
Error en pantalla -> "esto es el manejo de errores, la app no se cae"

SI NO SABES ALGO

No inventes.

Di: eso no lo medi, lo que si compruebo es esto otro.
Y llevalo a algo que si hiciste.